



CC 2026.1 | Projetos 6 | Grupo 4 - VOLTZ

Plano Técnico

1. Fontes dos Dados

1.1 Dados Próprios – Módulo de Estoque (CRUD Interno)

O próprio sistema gerará e armazenará os dados de estoque. Toda movimentação será registrada diretamente na base de dados da aplicação.

- **Entradas:** Entrada de produtos: data, quantidade, produto, lote, custo unitário.
- **Saídas/Ajustes:** Ajustes manuais: correções de inventário, perdas, vencimentos.

1.2 Dados Externos – API de Vendas

Uma API externa concentra todas as transações de venda da cafeteria. O sistema consumirá esses dados via integração para alimentar o modelo preditivo.

- **Transações:** Registro de cada venda: produto, quantidade, data/hora, valor.
- **Histórico:** Agrupamentos diários, semanais e mensais de consumo por produto.
- **Padrões:** Identificação de períodos especiais (feriados, eventos, sazonalidade).

1.3 Dados Externos – API de Fornecedores (Automação WhatsApp)

Uma API externa se baseia nas conversas de WhatsApp com os fornecedores e gera informações comparativas de fornecedores para subsidiar a funcionalidade de recomendação do melhor parceiro de compra.

- **Cotações:** Cotações de preço por produto, quantidade e período.
- **Prazo:** Prazo de entrega estimado para cada fornecedor e condição de compra.
- **Histórico de atendimento:** Notas de atendimento, ocorrências e avaliações anteriores.
- **Condições comerciais:** Condições de pagamento, frete e descontos por volume.

2. Formatos Disponíveis

Os dados serão obtidos e armazenados nos seguintes formatos:

Fonte	Formato de Troca	Armazenamento	Observações
Módulo de Estoque (interno)	Banco de dados relacional	SQL	Gerado pelo próprio sistema.
API de Vendas	JSON via REST	SQL / Data Lake	Consumo via endpoint HTTP.
API de Fornecedores	JSON via REST	SQL	Consumo via endpoint HTTP.

3. Volume Estimado

As estimativas abaixo consideram uma cafeteria de pequeno/médio porte com operação contínua ao longo do ano.

Fonte de Dados	Volume Estimado	Horizonte
Estoque (movimentações)	~500–1.500 registros/mês	Acumulativo desde implantação
Vendas (transações)	~3.000–10.000 registros/mês	Mínimo 12 meses para sazonalidade
Fornecedores (cotações/histórico)	~200–800 registros/mês	Atualizado por consulta ou período
Total acumulado (1 ano)	~50.000–150.000 registros	Volume adequado para ML supervisionado

O volume estimado é modesto, porém suficiente para técnicas supervisionadas como regressão e modelos baseados em árvores. Não há necessidade de infraestrutura de Big Data para este contexto.

4. Possíveis Desafios

4.1 Coleta e Integração de Dados

- **Granularidade da API de Vendas:** A API de Vendas pode não ter um endpoint com granularidade suficiente (ex.: vendas por produto por hora), exigindo transformações adicionais.
- **Inconsistência na API de Fornecedores:** A API de Fornecedores pode retornar cotações inconsistentes ou em formatos variados entre fornecedores distintos, demandando normalização.
- **Disponibilidade das APIs:** Falhas, timeouts ou mudanças de contrato nas APIs externas podem interromper o fluxo de dados e afetar a qualidade dos modelos.
- **Cold Start:** Sem histórico prévio, o sistema não terá dados suficientes nos primeiros meses para treinar modelos confiáveis (cold start).

4.2 Qualidade dos Dados

- **Dados ruidosos no estoque:** Entradas manuais no CRUD de estoque podem conter erros tipográficos, duplicidades ou registros incompletos.
- **Sazonalidade não mapeada:** A cafeteria pode ter picos sazonais (festas, datas comemorativas) que distorcem as previsões se não forem devidamente sinalizados.
- **Heterogeneidade de fornecedores:** A comparação de fornecedores só é significativa se todos os atributos (preço, prazo, qualidade) forem avaliados na mesma base.

4.3 Desafios Técnicos e Operacionais

- **Manutenção contínua dos modelos:** A necessidade de re treinamento periódico dos modelos exige uma rotina de MLOps, mesmo que simplificada.
- **Definição de critérios de decisão:** Combinar preço e prazo em uma única recomendação requer a definição de pesos ou funções de utilidade, que podem ser subjetivos.
- **Privacidade e segurança:** Dados de fornecedores e vendas podem ser sensíveis comercialmente, exigindo controle de acesso e cuidado no armazenamento.

5. Análise Preliminar de Viabilidade

A seguir é apresentada a análise de viabilidade para cada funcionalidade de Aprendizado de Máquina prevista no sistema.

5.1 Previsão de Compras

Objetivo: prever quais produtos precisam ser recomprados e em qual quantidade, com base no histórico de vendas e saídas de estoque.

- **Dados disponíveis:** Séries temporais de consumo por produto (coletadas da API de Vendas e do CRUD de Estoque).
- **Técnicas candidatas:** ARIMA/SARIMA para séries temporais; Random Forest Regressor ou Gradient Boosting (XGBoost/LightGBM) com features de lag, média móvel e indicadores sazonais.
- **Viabilidade:** Alta — problema bem definido, dados estruturados, ampla literatura e ferramentas open source disponíveis (scikit-learn, statsmodels, Prophet).
- **Condicionantes:** Necessidade de ao menos 6-12 meses de histórico para capturar sazonalidade; dados de eventos externos (feriados, promoções) aumentam a acurácia.

5.2 Recomendação do Melhor Fornecedor

Objetivo: dado um produto e uma quantidade necessária, recomendar o fornecedor mais adequado considerando preço, prazo de entrega e histórico de atendimento.

- **Dados disponíveis:** Cotações, prazos, notas de atendimento e condições comerciais vindos da API de Fornecedores.
- **Técnicas candidatas:** Classificação supervisionada (se houver rótulo de 'melhor escolha' histórica) ou otimização multicritério (TOPSIS, AHP) combinada com ranking por score ponderado.
- **Viabilidade:** Alta para abordagem baseada em regras/score ponderado; Média para classificação supervisionada (requer histórico rotulado de decisões passadas).
- **Condicionantes:** Definição clara dos pesos entre preço, prazo e qualidade; ausência de rótulos históricos pode exigir início com regras explícitas e evolução para ML à medida que dados acumulam.

Resumo de Viabilidade

Funcionalidade	Técnica Indicada	Viabilidade	Principal Risco
Previsão de Compras	SARIMA / XGBoost / Prophet	Alta	Volume insuficiente nos primeiros meses (cold start)
Recomendação de Fornecedor	Score ponderado / TOPSIS / Classificação	Alta (regras) / Média (ML)	Falta de rótulos históricos para aprendizado supervisionado